

Taller 1: Uso del tokenizador de subpalabras: SentencePiece

Tokenizador sentencepiece

A diferencia de los tokenizadores [WordPiece](#) y [\(BPE\)](#) que usan pretokenizadores para procesar la entrada, SentencePiece no, el cual trata la entrada como un flujo de entrada sin procesar y todo el procesamiento lo realiza de manera simultánea haciendo más rápido el tokenizador. Como un todo, SentencePiece es un tokenizador de texto no supervisado y destokenizador, que resuelve en principio el no tener el texto pretokenizado. SentencePiece implementa la tokenización de subpalabras usando [\(BPE\)](#) [\[Sennrich et al.\]](#) y el modelo de lenguaje [unigrama](#) [\[Kudo.\]](#) para construir el vocabulario con la extensión del entrenamiento directo a partir de oraciones en bruto (raw text). SentencePiece nos permite crear un sistema puramente de extremo a extremo que no depende del pre/postprocesamiento específico del idioma. Hay varios modelos de transformers que usan SentencePiece, tales como: [ALBERT](#), [XLNet](#), [MarianMT](#) y [T5](#). Una de las características importantes de SentencePiece es que usa un pretokenizador específico para cada idioma y soluciona el problema con el tokenizador y destokenizador: En pocas palabras con SentencePiece podemos modelar los demás tokenizadores de subpalabras

Objetivo del quiz

El objetivo del quiz es el de realizar varios tests del algoritmo de SentencePiece sobre el dataset de [word billion](#) de [Hugging Face](#).

Problema:

Para resolver el quiz usaremos el dataset [word billion](#) de [Hugging Face](#) con el que vamos a resolver las siguientes subareas.

1. Instalar los datasets desde [Hugging Face](#).
2. instalar la librería de [SentenciaPiece](#)
3. Cargar el dataset de entrenamiento de [word billion](#)
4. Crear una rutina para convertir el dataset en un conjunto de archivos de texto ya que la entrada a [SentenciaPiece](#) son archivos de texto. Es importante tener en cuenta que como [word billion](#) es muy grande hay que particionarlo en archivos de texto para poder entrenarlo con Sentencepiece. Aquí un parte del código.

```
from tqdm.auto import tqdm # for our loading bar

text_data = []
file_count = 0

for sample in tqdm(all_wiki):
    # remove newline characters from each sample as we need to use exclusively as separators
    sample = sample['text'].replace('\n', '\s')
    text_data.append(sample)
    if len(text_data) == 5_000:
        # once we hit the 5K mark, save to file
        with open(f'./wiki2/text_{file_count}.txt', 'w', encoding='utf-8') as fp:
            fp.write('\n'.join(text_data))
        text_data = []
        file_count += 1
# after saving in 5K chunks, we may have leftover samples, we save those now too
with open(f'./wiki2/text_{file_count}.txt', 'w', encoding='utf-8') as fp:
    fp.write('\n'.join(text_data))
```

5. Entrenado el tokenizador con SentencePiece se deben usar los siguientes prefijos para tokenizar hasta cinco sentencias:

5.1 Prefijo de bpe con vocabularios de 10000, 20000 y 30000

5.2 Prefijos que usa [WordPiece](#) tales como <sep> y <cls>

5.3 prefijo de word

5.4 Prefijo para tipo char