

Quiz: Semántica vectorial clásica

Semántica vectorial clásica: Tf-idf y ley de cosenos

La semántica vectorial clásica es considerada la base fundamental de la semántica vectorial escalada y se soporta en el principio básico de la similaridad semántica. En ésta tarea se van a trabajar dos conceptos ; uno el tf-idf entre las palabras de un documento y el la ley de cosenos como el primer principio fundamental de similaridad semántica.

Objetivo del quiz

El objetivo del quiz es el de resolver la relación semántica de similaridad entre documentos usando las técnicas de tf-idf y ley de cosenos entre vectores.

Problema

Dado el conjunto de términos (palabras) VS Novelas:

	As You Like It	Twelfth Night	Julius Caesar	Henry V
battle	1	0	7	13
good	114	80	62	89
fool	36	58	1	4
wit	20	15	2	3

Analizar la similitud entre cuatro obras de Shakespeare utilizando representaciones vectoriales, la ley de cosenos y técnicas modernas de procesamiento de lenguaje natural como TF-IDF y reducción de dimensionalidad.

Datos

Se tienen cuatro obras representadas mediante vectores de frecuencia de términos, donde cada dimensión corresponde a la frecuencia de las palabras: (**battle, good, fool, wit**).

- **As You Like It** $\rightarrow (1, 114, 36, 20)$
- **Twelfth Night** $\rightarrow (0, 80, 58, 15)$
- **Julius Caesar** $\rightarrow (7, 62, 1, 2)$
- **Henry V** $\rightarrow (13, 89, 4, 3)$

Puntos a resolver

1) Obtener la matriz tf-idf y luego aplicar la normalización L2 para la ponderación y comparabilidad de las palabras de cada obra.

2) Calcular la similitud coseno entre las obras usando las frecuencias ponderadas de las palabras con tf-idf con el fin de encontrar la novela más similar a la novela **Henry V**.

3) Calcular la similitud del coseno entre las obras con las frecuencias crudas de la tabla con el fin de encontrar la novela más similar a la novela **Henry V**.

4) Compare la similitud del coseno usando las frecuencias crudas y la ponderación de tf-idf y responda las siguientes preguntas: ¿Qué corrige la técnica de tf-idf, qué es lo que se penaliza?, ¿Con las frecuencias crudas qué hace que **Henry V= Julius Caesar=0.999** sean similares ?

5) Aplique una técnica de reducción de dimensionalidad:

- PCA (recomendada), o
- Tsne (opcional)

Visualizar los documentos en el plano cartesiano para cada uno de los modelos

- Similitud coseno + tf-idf
- Similitud coseno + frecuencias crudas