

Modelo de atención de Vaswani

El creciente desarrollo de los modelos preentrenados como BERT, GPT, ELECTRA y T5 ha impulsado las tareas fundamentales del Procesamiento del Lenguaje Natural (PLN) y motivado la producción de los grandes modelos del lenguaje (LLMs). Este avance tiene su origen en 2017, cuando [Vaswani](#) et al. presentaron en Google Research el artículo "*Attention is All You Need*", un hito que transformó radicalmente el campo de la inteligencia artificial. En este taller se implementará una versión básica del mecanismo de atención escalada, componente principal de la arquitectura Transformer y fundamento de la similitud semántica que hoy caracteriza a los LLMs modernos.

Objetivo general

El objetivo del taller implementar un modelo de attention básico que tiene como entrada una oración o sentencia y al final el algoritmo debe imprimir la relación semántica de las palabras de la oración basado en el modelo de [Vaswani](#)

Tarea

Dada una sentencia de entrada obtener su **vector de contexto** basado en el modelo de atención de Vaswani, tanto para BERT como para GPT

↑ ↓ ✎ 🗑 ⋮

Autoatención Escalada: BERT (Encoder) vs GPT (Decoder)

Este notebook extiende el mecanismo de autoatención escalada del Transformer de Vaswani et al. (2017) para comparar los dos usos principales:

Aspecto	BERT (Encoder)	GPT (Decoder)
Dirección	Bidireccional — cada token ve todos	Causal — cada token solo ve tokens anteriores
Máscara	Sin máscara	Máscara triangular inferior
Uso	Clasificación, NER, Q&A	Generación de texto

Ecuación compartida:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$

Donde $M = 0$ para BERT y $M_{ij} = -\infty$ si $j > i$ para GPT.

Para ello tenga en cuenta

1. Lee la oración por `input()` y la convierte a IDs enteros usando un vocabulario dinámico. El embedding de las matrices de proyección W_Q , W_K , W_V y del modelo es de igual a 16.
2. Reproduce exactamente el flujo del notebook: embedding $\rightarrow$ Q, K, V con pesos aleatorios
3. Calcula los *attention scores* escalados con la fórmula de Vaswani:

4. BERT: aplica **softmax** directamente sobre todos los scores (atención bidireccional)
5. GPT: crea una máscara causal triangular inferior y rellena con -inf la parte superior antes del softmax
6. Imprime y grafica las matrices de atención lado a lado de la sentencia de entrada
7. Explique de manera detallada en la siguiente tabla cada una de las preguntas

	BERT	GPT
¿Cómo es la matriz de atención?		
¿Existe algún orden secuencial como en los LSTMs?		
¿Cuál es la diferencia en la atención de las palabras?		
¿Qué tipo de contexto capturan?		
¿Para qué es ideal?		